

Report Data Mining

1. Descrizione e pulizia del dataset

Il dataset contiene informazioni relative a 12800 case di Milano: per 8000 sono disponibili il prezzo di vendita e variabili di input che descrivono le caratteristiche dell'immobile, mentre per le restanti 4800 solo quest'ultime e l'obiettivo è stimarne il prezzo. Originariamente sono presenti 15 variabili di input, tra cui "other_features", una lista di caratteristiche aggiuntive di ogni genere: se una caratteristica è presente, è indicata nella variabile, altrimenti è assente. Una volta elaborata, porta alla creazione di 61 variabili dummy, una per ciascuna caratteristica, per un totale di 75 variabili di input.

Al termine di modifiche alle variabili e varie imputazioni si hanno 33 variabili di input:

Variabile	Descrizione	Tipo e trattamento dati
square_meters	Dimensione in mq	Se ≤ 12 imputati con regressione lineare; numerica
bathrooms_number	Numero di bagni	Se > 3 messo valore 4, numerica
lift	Ascensore	Variabile binaria
rooms_number	Numero di stanze	Se > 5 messo valore 6, numerica
total_floors_in_building	Piani edificio	NA con regressione logistica cumulata (polr) ¹
car_parking	Parcheggio	4 livelli
condominium_fees	Tasse condominiali	NA con media per gruppi ²
year_of_construction	Anno di costruzione	NA con media per gruppi, divisa poi in 7 fasce temporali
conditions	Condizioni immobile	NA con polr, 4 livelli
zone	Zona di Milano	Ridotte da 146 a 19 con analisi cluster
distance	Distanza dal Duomo	Calcolata con coordinate di ogni zona originale; numerica
floor	Piano	Numerica
heating_centralized	Tipo riscaldamento	NA con regressione logistica
energy_efficiency_class	Classe energetica	4 livelli; NA con polr
optic_fiber	Fibra ottica	Binaria
security_door	Porta blindata	Binaria
cellar	Cantina	Binaria
video_entryphone	Videocitofono	Binaria
alarm_system	Allarme	Binaria
closet	Cabina armadio	Binaria
electric_gate	Cancello elettrico	Binaria
furnished	Arredamento	3 livelli
terrace	Terrazza	Binaria
hydromassage	Idromassaggio	Binaria
fireplace	Camino	Binaria
tavern	Taverna	Binaria
attic	Mansarda	Binaria
pool	Piscina	Binaria
tennis_court	Campo da tennis	Binaria
concierge.reception	Portineria	Binaria, unione di più variabili dummies
exposure	Esposizione	Categoriale: singola o doppia
balconies	Balconi	Binaria, unione di più variabili dummies
garden	Giardino	3 livelli





2. Costruzione e selezione del modello

Un'analisi grafica preliminare della variabile risposta `selling_price` (Figura 1) ha evidenziato come potesse essere opportuno utilizzare una trasformazione logaritmica: di conseguenza, tutti i modelli sono stati costruiti prevedendo come variabile risposta $\log(\text{selling_price})$. Inoltre, applicando il logaritmo si osserva una riduzione della dispersione dei dati, come evidenziato dai boxplot (Figura 2). Dall'esplorazione delle altre variabili, è emerso come anche una trasformazione logaritmica per la variabile `square_meters` risulti conveniente, sia osservando la sua distribuzione (Figura 3) sia analizzando

¹ La regressione logistica cumulata (polr) è stata adottata in presenza di variabili ordinali, essendo appropriata per modellare la probabilità cumulata associata a ciascun livello della variabile, preservando l'ordinamento naturale delle categorie.

² Media per gruppi: calcola la media della variabile da imputare in base a raggruppamenti di altre variabili.

la relazione con il logaritmo di `selling_price` (Figura 4). Per gli altri regressori, invece, non sembrano esserci trasformazioni appropriate.



Prima di procedere alla costruzione dei modelli predittivi, il dataset per cui è disponibile l'informazione sul prezzo di vendita è stato diviso in due parti distinte: un training set, contenente il 75% delle osservazioni (6000), ed un validation set con le rimanenti unità (2000). I modelli sono stati dunque addestrati sul set di train e successivamente valutati sul set di validation, utilizzando principalmente come indice di performance l'errore assoluto medio (MAE).

Inizialmente, come primo approccio, è stato utilizzato un modello lineare avente come variabile risposta `selling_price`, senza applicare alcuna trasformazione, ed includendo come regressori tutte le variabili disponibili, anch'esse non trasformate. Successivamente, tenendo conto delle considerazioni fatte sulla distribuzione del prezzo di vendita, si è stimato un secondo modello lineare in cui è stata applicata una trasformazione logaritmica alla variabile risposta, mantenendo invariati i regressori. Infine, è stato costruito un terzo modello in cui, oltre alla trasformazione applicata al prezzo di vendita, anche la variabile `square_meters` è stata trasformata tramite logaritmo come osservato precedentemente, al fine di migliorare la linearità. Ovviamente, in quest'ultimo caso la variabile `log(square_meters)` è stata inclusa nel modello al posto della versione non trasformata, che è stata opportunamente esclusa.

Il confronto delle performance di questi tre modelli ha evidenziato come l'ultimo sia quello con il comportamento predittivo migliore: infatti, l'errore assoluto medio, valutato sempre sullo stesso validation set, si è ridotto di oltre 25000 euro, confermando l'efficacia delle considerazioni preliminari fatte sulla possibilità di applicare trasformazioni logaritmiche.

Tutti questi modelli includono un totale di 71 covariate ciascuno, derivanti da variabili numeriche, categoriche e dummies. Tuttavia, un numero comunque piuttosto elevato di predittori può aumentare il rischio di overfitting e ridurre l'interpretabilità del modello. Per questo motivo, l'obiettivo è quello di individuare un sottoinsieme più parsimonioso di variabili in grado di mantenere, o possibilmente migliorare, le capacità predittive del modello.

A tal proposito, sono state effettuate due distinte procedure di selezione delle variabili di tipo backward best subset, entrambe a partire dal modello completo con le trasformazioni adeguate. I due metodi hanno adottato come criteri, rispettivamente, l'Akaike Information Criteria (AIC) ed il MAE calcolato sul validation set. Il primo ha consentito di individuare modelli più parsimoniosi, penalizzando la complessità, il secondo, invece ha misurato direttamente la capacità predittiva.

Queste strategie hanno portato all'eliminazione di una serie di variabili con scarso contributo informativo o che causano

ridondanza: car_parking, heating centralized, video_entryphone, hydromassage, fireplace, tavern, attic, tennis_court, exposure. La riduzione ha comportato un passaggio da 71 a 60 covariate, mantenendo un MAE piuttosto simile.

Allo scopo di ridurre ulteriormente il numero di covariate e migliorare la parsimonia del modello, è stato effettuato un accorpamento ragionato di alcune variabili dummies, inizialmente contenute nel carattere other_features, che descrivono aspetti simili dell'abitazione. Quest'intervento è stato condotto prendendo in considerazione esclusivamente le variabili ancora presenti nel modello dopo la procedura di selezione backward best subset, escludendo dunque quelle già eliminate in quanto ridondanti o poche informative. In particolare, sono state create nuove features categoriali, tramite la somma delle relative variabili binarie; successivamente sono state convertite in formato numerico. In dettaglio sono state definite:

- security_level: somma delle variabili security_door, alarm_system ed electric_gate; si riferisce ad un livello di sicurezza offerto dalla casa;
- luxury_level: somma delle variabili closet e pool; si tratta di un indicatore del livello di lusso dell'abitazione.

Queste trasformazioni permettono di preservare il contenuto informativo delle variabili originale, riducendo la dimensionalità. Infatti, prima di renderle numeriche, si osserva come questi due nuovi livelli influiscano sul prezzo, specialmente tra il livello 0 ed il livello massimo (Figura 5 e Figura 6).




Figura 5 - Boxplot di security_level




Figura 6 - Boxplot di luxury_level

Il modello ottenuto, con un numero di covariate pari a 57, è dunque il seguente:

```
lm_mod = lm(
  log(selling_price) ~ log(square_meters) +
    bathrooms_number + lift + rooms_number +
    total_floors_in_building + condominium_fees +
    year_of_construction + conditions + zone + floor +
    energy_efficiency_class + optic.fiber + cellar + furnished +
    terrace + concierge.reception + balconies + garden +
    distance + luxury_level + security_level,
  data = train)
```

Nel corso dell'analisi si è provato anche a valutare la possibile presenza di interazioni tra alcune variabili, come zone e optic_fiber, bathrooms_number e rooms_number o energy_efficiency_class e year_of_construction ed altre ancora, ipotizzando che l'effetto congiunto potesse fornire un contributo rilevante alla previsione del prezzo. Tuttavia, nessuna di queste interazioni ha portato ad un miglioramento della stima, per cui si è preferito preservare un modello più semplice ed interpretabile.

In una fase finale dell'analisi sono stati esplorati anche modelli di regressione penalizzata, tra cui Ridge regression, Lasso regression ed Elastic Net, con lo scopo di migliorare la capacità predittiva e gestire problemi di multicollinearità tra le covariate. Tuttavia, i risultati ottenuti, valutati in termini di errore assoluto medio, non hanno mostrato importanti miglioramenti rispetto al modello di regressione lineare già stimato. Pertanto, si è preferito mantenere quest'ultimo modello, che presenta il vantaggio di essere più semplice da interpretare.

A conclusione delle precedenti analisi e considerazioni, tutte le modifiche applicate al set di dati di cui è disponibile il prezzo sono state applicate al test set, al fine di stimare il prezzo secondo il modello costruito.

3. Interpretazione del modello finale

Il modello di regressione lineare multivariata stimato sul logaritmo del prezzo di vendita mostra buone performance esplicative, con un R^2 pari a 0.9078, indicando che molta della variabilità della variabile risposta $\log(\text{selling_price})$ è spiegata dalle variabili incluse nel modello. Numerose variabili risultano essere statisticamente significative, presentando p-value minori di 0.05; in particolare, si evidenziano il logaritmo della superficie in metri quadri, il numero di bagni, la presenza dell'ascensore, il numero di stanze, le condizioni dell'immobile, la zona, il piano, tutte variabili che si poteva pensare essere significative fin dall'inizio dell'analisi.

In particolare, come prevedibile, la superficie dell'immobile ha un effetto positivo molto marcato sul prezzo, coerentemente con un'intuizione economica. Inoltre, le zone di Milano, come si poteva prevedere, mostrano forte differenze di prezzo, con effetti crescenti man mano che ci si sposta verso zone più di prestigio o centrali.

I residui risultano essere distribuiti in modo circa simmetrico intorno allo zero (Figura 7), con valori tra -2.28 e 1.77 circa, con un errore standard di 0.1935; non emergono particolari problematiche di eteroschedasticità o outliers.




Figura 7- Grafico dei residui

4. Conclusione

In conclusione, il modello lineare costruito con trasformazioni logaritmiche ed una selezione accurata delle variabili mostra una buona capacità predittiva ed un'elevata interpretabilità.

Le variabili più significative, quali la metratura, il numero di bagni e stanze, la zona, le condizioni dell'immobile, risultano coerenti con un'interpretazione economica plausibile. Si sottolinea inoltre come poche delle features incluse nel modello derivassero dal gruppo delle variabili `other_features`.

I principali limiti del modello, e dunque della sua capacità predittiva, sono dovuti alla massiccia presenza di valori mancanti o anomali nel dataset iniziale.

Nonostante queste criticità, il modello costituisce una buona base per la stima dei prezzi immobiliari nella città di Milano.

Sommario

1. Descrizione e pulizia del dataset	1
2. Costruzione e selezione del modello	1
3. Interpretazione del modello finale	4
4. Conclusione	4